

# İHA Destekli Tarım İçin Sinir Ağı ile Bitki Hastalıklarının Sınıflandırılması

## Classification of Plant Diseases with Neural Network for UAV-Assisted Agriculture

Sude Nur Tungaç  
Bilgisayar Mühendisliği  
Marmara Üniversitesi  
İstanbul, Türkiye  
sudenurtungac@gmail.com

**Özetçe**—Bu çalışmada, bitki hastalıklarının geç tespiti dolayısıyla verimliliğin azalması probleminde bir çözüm olarak insansız hava araçlarına entegre şekilde çalışabilecek bir bitki hastalık tespiti modeli üzerinde deneyler yapılmıştır. Sinir ağı tabanlı çeşitli modellerin test edilmesi ile en verimli algoritmanın bulunması hedeflenmiştir. Modeller patates bitkilerinin hastalıklı ve sağlıklı görüntüleri üzerinde eğitilmiştir. Bu doğrultuda VGG16, LeNet, ResNet, GoogleNet ve MobileNet gibi CNN tabanlı yapay zekâ modelleri test edilmiş ve performansları analiz edilmiştir.

**Anahtar Kelimeler** — bitki hastalığı tespiti; tarımda yapay zekâ; VGG16; LeNet; ResNet; GoogleNet; MobileNet.

**Abstract**— In this study, experiments were conducted on a plant disease detection model that can be integrated with unmanned aerial vehicles as a solution to the problem of decreased efficiency due to late detection of plant diseases. The aim was to find the most efficient algorithm by testing various neural network-based models. The models were trained on diseased and healthy images of potato plants. In this direction, CNN-based artificial intelligence models such as VGG16, LeNet, ResNet, GoogleNet and MobileNet were tested and their performances were analyzed.

**Keywords** — plant disease detection; artificial intelligence in agriculture; VGG16; LeNet; ResNet; GoogleNet; MobileNet.

### I. GİRİŞ

Bitki yetiştiriciliği, insanlık tarihinin başından beri süregelen bir uğraş olmuştur. Sağlıklı bitkilerin ekilmesi ve büyütülmesi sürecinin sonunda elde edilen hasadın gıda, ilaç, endüstriyel alanlarda malzeme yapımı ve daha birçok alanda kullanılması söz konusudur [1]. Bitkilerin günlük yaşamdaki yeri göz önüne alındığında, vazgeçilmezliği kolaylıkla gözlemlenebilir. Bu durumdan dolayı bitki yetiştirilmesi işlemlerinden elde edilen verimliliğin artırılması için çeşitli çalışmalar yapılmıştır ve yapılmaya devam edilmektedir. Sera ve bahçelerde yetiştirilen domates, patates ve biber gibi bitkilerde çeşitli hastalıklar görülebilir [2]. Bitkilerdeki hastalıklar ürünlerin zarar görmesine sebep olur ve hastalıkların geç fark edilmesi durumunda hastalığın yayılması söz

konusudur. Bu durumda çiftçiler için bitki hastalıklarının erken tespiti büyük önem taşıyan bir konudur. Bitkilerdeki hastalıkların yapraklar aracılığı ile tespitinin yapılabilmesi için bitkilerin düzenli aralıklarla incelenmesi gerekir. Ancak bu inceleme insan gücü ile yapıldığında işçi ve zaman maliyeti, hastalıklı yaprak sınıflandırmasında insan gözü ile yapılan incelemelerde yapılabilen hatalar, hastalıkların geç tespiti gibi durumlar söz konusudur. Bitki yapraklarının incelenmesi ile hastalık tespitinin otomatikleştirilmesi için insansız hava araçlarının kullanımı gibi çözümler üzerinde yapılan çalışmalar bulunur [3]. Bu çalışmada ise insansız hava araçlarına entegre bir şekilde çalışabilecek ve bu aracın kamerasından alacağı patates bitkisi yaprağı görüntülerini sınıflandırarak hasta bitki tespitini yapabilecek yapay sinir ağı modelleri üzerine gerçekleştirilen deneylerden bahsedilmektedir. Çalışmaya Github üzerinden ulaşılabilir: <https://github.com/stungac/potato-disease-detection>.

### II. LİTERATÜR TARAMASI

(R. P. Mr. ve ark., 2023) tarafından yapılan çalışmada PlantVillage veri setinden faydalanılarak dolmalık biber, patates ve domates bitkilerine ait 20.000 adet görüntü kullanılmıştır. Bu bitki hastalıklarının tespiti için geliştirilen CNN tabanlı modelin mimarisinde 6 evrimsel katman, 6 havuzlama katmanı bulunur. Optimizasyon için ise adam algoritması ve kategorik çapraz entropi kaybı fonksiyonu kullanılmıştır. Çalışmada ayrıca web tabanlı bir arayüz de geliştirilmiş ve arayüzün kullanımı ile bitki hastalığı tahmininin gerçekleştirilmesine olanak sağlanmıştır.

(Aldakheel ve ark., 2024) tarafından yapılan çalışmada ise PlantVillage veri seti üzerinde Densenet, AlexNet, RCNN (Region-based CNN), SqueezeNet, ResNet, Hybrit CNN, KNN ve YOLOv4 modellerinin performansları test edilmiş ve karşılaştırılmıştır. Yapılan karşılaştırma sonucunda YOLOv4 modelinin diğer modellere kıyasla daha verimli ve daha doğru sonuçlar elde ettiği görülmüştür.


(Gülmez B. ve ark., 2024) tarafından yapılan çalışmada patates hastalıklarının tespiti için PlantVillage veri seti ve özel

olarak sahadan toplanan görsel verileri kullanılmıştır. CNN tabanlı modellerin kullanımından önce veriler ön işlenmiştir. Daha sonrasında ResNet, VGG-16, VGG-19, MobileNet, DenseNet ve EfficientNet modelleri kullanılarak hastalıklı ve sağlıklı bitkilerin sınıflandırılması işlemi gerçekleştirilmiştir.

### III. METOT

#### A. Veri Seti Analizi

Çalışmada içeriğinde patates bitkilerinin yapraklarına ait sağlıklı ve hastalıklı görseller içeren Potato Disease Leaf DataSet (PLD) veri seti kullanılmıştır. Veri seti Kaggle platformu üzerinden erişime açıktır. Bu veri seti içerisinde patates bitkisine ait 3 sınıf bulunur. Veri setinde toplamda 4.072 görsel bulunur. Veri seti içerisindeki görseller 256x256 boyutundadır. Görsellerin sınıflara göre dağılımı Şekil 1’de gösterilmiştir. Eğitim veri setinin boyutu 3251, doğrulama veri setinin boyutu 416 ve test veri setinin boyutu 405 olarak ölçülmüştür.

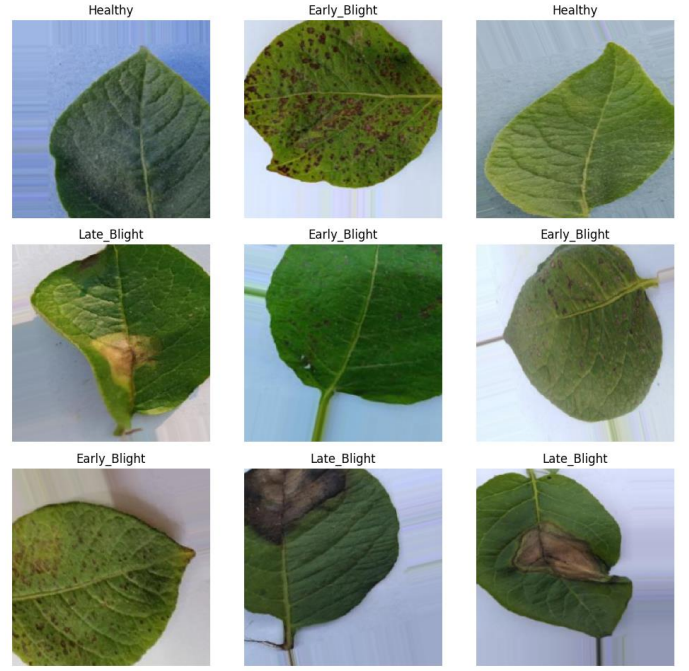


Şekil. 1. Sınıflara göre veri dağılımı.

#### B. Veri Ön İşleme Adımları

Eğitim veri setindeki görsellerin çeşitlendirilmesi amacı ile görsellere veri agümantasyonu işlemleri uygulanmıştır. Bu tekniğin kullanılması sırasında görsellerin sağa veya sola döndürülmesi, çeşitli rotasyonlarda kaydırılması, rastgele yakınlık değişimi uygulanması işlemleri gerçekleştirilmiştir. Daha sonrasında ise görsellerin yeniden boyutlandırılması ile ilgili işlemler uygulanarak görseller 224x224 boyutuna indirgenmiştir. Görsellerin kanal sayısı ise 3 olarak belirlenmiştir. Normalizasyon işlemi gerçekleştirilen görseller 0-255 aralığına getirilmiştir. Bu işlemlerin ardından elde edilen görseller kullanıma hazır hale getirilmiştir. Şekil 2’de eğitim veri setinin ön işleme adımlarından sonra içerdiği görsellere yer verilmiştir.

Eğitim Veri Setinden Örnek Görseller



Şekil. 2. Ön işleme adımlarından sonra eğitim veri setinden örnek görseller.

#### C. Kullanılan Yöntem ve Modeller

Çalışma sürecinde CNN tabanlı modellerin kullanımı ile patates bitkisi yapraklarının hastalıklarına göre sınıflandırması işlemi gerçekleştirilmiştir. Bu süreçte test edilmiş olan modeller şu şekildedir:

**VGG16:** VGG16, toplamda 16 öğrenilebilir katmana (13 konvolüsyonel ve 3 tam bağlantılı) sahiptir. Konvolüsyonel katmanlarda sabit olarak 3x3 boyutunda filtreler ve 1 adımlık (stride = 1) kaydırma kullanılmıştır. Max-pooling işlemi 2x2 filtrelerle gerçekleştirilmiştir. Özellikle transfer öğrenme için çok uygundur. Derinliği sayesinde yüksek doğruluk sağlar. Ancak yüksek parametre sayısı nedeniyle eğitim ve çıkarım süreci oldukça maliyetlidir. Gömülü sistemlerde kullanımı zordur.

**LeNet:** LeNet-5, toplamda yedi katmandan oluşmaktadır. Girdi katmanı genellikle 32x32 boyutlarında gri tonlamalı görselleri kabul eder. Yapıda sırasıyla konvolüsyonel katmanlar, ortalama havuzlama (average pooling) katmanları ve tam bağlantılı (fully connected) katmanlar yer almaktadır. Basit ve anlaşılır bir yapıya sahiptir, ayrıca küçük veri kümeleri üzerinde yüksek performans sağlar. Ancak Düşük kapasiteli olması nedeniyle yüksek çözünürlüklü veya karmaşık görsellerde yetersiz kalmaktadır.

**ResNet:** Gradyan kaybolma probleminin önüne geçilmesi için her bir residual block, giriş bilgisinin çıktıya direkt olarak taşınmasını sağlayan skip connection içerir. Denklem (1), residual bloğun formülünü temsil eder. Burada  $x$  giriş verisini,  $F(x, \{W_i\})$  konvolüsyon ve aktivasyon işlemleri sonucu elde edilen çıktıyı ve  $y$  son çıktıyı ifade eder.

$$y = F(x, \{w_i\}) + x \quad (1)$$

ResNet152V2 modeli 152 katman içerir ve temelde ön işleme, 3 adet residual bölge, çıkış katmanını yapılarından oluşur. Skip bağlantılar sayesinde gradyan kaybının olmaması, batch normalizasyon öncelikli olduğundan eğitimin stabil ilerleyebilmesi, derin özellikleri öğrenme konusunda başarılı olması gibi nedenlerden ötürü çalışmada kullanılmaktadır. [6]

**GoogleNet:** Bu modelin temel farkı, Inception modülü adı verilen özel yapı sayesinde, farklı boyutlardaki filtrelerle aynı anda konvolüsyon uygulanabilmesidir. Böylece model hem genişlik hem de derinlik açısından zengin bir yapı sunar. 1x1 konvolüsyonlar, hem boyut indirgeme hem de hesaplama verimliliği için kullanılır. Bu sayede parametre sayısı düşerken performans korunur. Hesaplama açısından oldukça verimlidir ancak yapının özelleştirilmesi ve genişletilmesi diğer mimarilere kıyasla daha zordur.

**MobileNet:** Özellikle mobil ve gömülü cihazlar için tasarlanmış hafif bir konvolüsyonel sinir ağı mimarisidir. Bu mimarinin temel amacı, düşük hesaplama gücüyle yüksek doğruluk sağlamaktır. Standart konvolüsyon yerine iki adımlı bir yaklaşım kullanır. Depthwise Convolution ile her kanal için ayrı konvolüsyon uygulanır. Pointwise Convolution ile ise 1x1 konvolüsyon ile derinlik birleştirilir. Bu iki aşamalı yapı sayesinde, parametre sayısı ve hesaplama maliyeti önemli ölçüde azalır.

Proje sürecinde, bahsedilen modellerin ilgili veri seti üzerinde test edilmesi ve sonuçlarının yorumlanması gerçekleştirilmiştir [7]. Çalışma sonucunda en başarılı sonucu veren modelin kullanıcı tarafından patates bitkisi hastalığı konusunda test edilebilmesi için kullanıcı arayüzü geliştirilmiştir. Arayüz ile ilgili işlemler Python kütüphanelerinden Tkinter ile gerçekleştirilmiştir. Bu arayüzde kullanıcı seçtiği patates yaprağı görselinin sağlıklı, erken yanıklık ve geç yanıklık sınıflarından hangisine ait olduğunu öğrenebilmektedir.

#### D. Model Eğitimi ve Değerlendirme Teknikleri

Çalışmada VGG16, LeNet, ResNet, GoogleNet ve MobileNet modellerinin eğitimleri için giriş görüntüsü boyutu 224x224 olarak belirlenmiş ve sınıf sayısı 3 (Early Blight, Late Blight, Healthy) olarak alınmıştır. Modellerin eğitiminde batch\_size=32, epochs=10 ve categorical\_crossentropy kayıp fonksiyonu tercih edilmiştir. Optimizasyon için tüm modellerde Adam kullanılmıştır. Overfitting'i önlemek amacıyla EarlyStopping mekanizması uygulanmıştır.

Çalışmada, eğitilen modellerin performansının incelenmesi konusunda tercih edilen metrikler doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), f1-skoru (f1-score) ve karmaşıklık matrisi (confusion matrix) olarak belirlenmiştir.

#### IV. BULGULAR VE TARTIŞMA

##### A. Yapılan Çalışmalar

Çalışmada VGG16, LeNet, ResNet, GoogleNet ve MobileNet model mimarileri tercih edilmiştir. Bu modellerin eğitimleri sonucunda elde edilen sonucun değerlendirme metriklerine göre ifadesi Tablo 1'de gösterilmiştir.

TABLO I. EĞİTİM SONRASINDA MODELLERİN TEST VERİ SETİ ÜZERİNDEKİ SONUÇLARI

Model	Başarı Metrikleri			
	Precision	Recall	F-1 Score	Accuracy
VGG16	0.86	0.86	0.85	0.86
LeNet	0.83	0.81	0.82	0.83
ResNet	0.96	0.97	0.97	0.97
GoogleNet	0.95	0.95	0.95	0.96
MobileNet	0.92	0.91	0.91	0.91

Modellerin eğitim sürecinde doğrulama veri seti üzerinde elde ettikleri kayıp (loss) değerleri karşılaştırılmıştır. Bu karşılaştırma sonucunda en düşük kayıp değerlerinin 0.16 ve 0.11 ile sırasıyla ResNet ve GoogleNet modellerinde elde edildiği görülmüştür.

##### B. Sonuçların Değerlendirilmesi

Modellerinin eğitilmesi ile Potato Disease Leaf DataSet (PLD) veri seti üzerinde yapılan sınıflandırma sonucunda ResNet modelinin diğer modellere göre daha başarılı metrik değerlerine ulaştığı görülmektedir. Ancak modellerin kayıp değerleri incelendiğinde ResNet ile arasında 0.05 boyutunda bir fark olan GoogleNet modeli öne çıkmaktadır. Yapılan çalışmalarda metriklerin değerlendirilmesinin ardından ana model olarak ResNet modeli seçilmiştir.

#### V. SONUÇLAR

Çalışma süresince VGG16, LeNet, ResNet, GoogleNet ve MobileNet modelleri kullanılmıştır. Elde edilen sonuçlar incelendiğinde patates bitkilerinin yaprakları üzerinden hastalıklı bitki sınıflandırmasında CNN tabanlı modellerin başarılı sonuçlar verebildiği görülmüştür. Başarı metrikleri incelendiğinde ResNet modelinin, elde edilen %97 doğruluk skoru ile diğer modellerden daha iyi performans gösterdiği görülmüştür.

Yapılan çalışmalar sonucunda elde edilen modelin, insansız hava araçlarına entegre edilebilecek hastalıklı bitki sınıflandırması modeli olarak kullanılması hedefine ulaşılmıştır. Bu çalışmaya, nesne tespiti modellerinin eklenmesi ve tespit edilen yaprak üzerinde sınıflandırma yapılmasının projenin gelişmesine katkı sağlayacağı düşünülmektedir.

#### KAYNAKLAR

- [1] T.C. Tarım ve Orman Bakanlığı, *Patates Aralık Bülteni*, Aralık 2019. [Çevrimiçi]. [Erişim tarihi: 25 Mart 2025].
- [2] T.C. Tarım ve Orman Bakanlığı, *Domates Hastalık ve Zararlıları ile Mücadele*, [Çevrimiçi]. [Erişim tarihi: 25 Mart 2025].
- [3] North Carolina State University, *Robots, drones, AI: Hardier tomatoes*, Mart 2024. [Çevrimiçi]. [Erişim tarihi: 25 Mart 2025].
- [4] R. P. Mr., R. R. L. Dr., H. R. S., ve H. C. V., *Detecting Leaf Diseases in Bell Pepper, Potato, and Tomato Plants using Convolutional Neural Network*, *International Journal of Innovative Science and Research Technology*, cilt 8, sayı 10, ss. 511-517, Ekim 2023.
- [5] Aldakheel, E. A., Zakariah, M., & Alabdallal, A. H. (2024). *Detection and Identification of Plant Leaf Diseases Using YOLOv4*. *Frontiers in Plant Science*, 15, 1355941.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition", *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, ss. 770-778.
- [7] A. Bochkovskiy, C.-Y. Wang, ve H.-Y. M. Liao, "YOLOv4: Optimal Speed and Accuracy of Object Detection", 2020.

- [8] B. Gülmez, "A Comprehensive Review of Convolutional Neural Networks based Disease Detection Strategies in Potato Agriculture", *Potato Research*, vol. 0123456789, 2024. DOI: 10.1007/s11540-024-09786-1.